Министерство образования и науки Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления» (ИУ)

КАФЕДРА «Системы обработки информации и управления» (ИУ5)

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

«Использование алгоритма CatBoost для выявления факторов, ведущих к увольнению сотрудников»

Студент группы ИУ5-31М _____ Маматкулов У.Б.

Руководитель _____ Гапанюк Ю.Е.

2021 г.

Содержание

Введение

Для работодателей очень важно анализировать причины увольнения своих сотрудников. В данной куровой работе будет использован датасет, позволяющий выявить основные факторы, приводящие сотрудника к неудовлетворённости своей работой. Будет проведена подготовка данных и их анализ. С использованием библиотеки CatBoost будут выявлены факторы ведущие к увольнению сотрудников.

Исследование данных

Установка пакета Yandex CatBoost

```
!pip install catboost
```

Импорт необходимых пакетов: Numpy, Pandas, Matplotlib, Seaborn, Scikit-learn и CatBoost

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler
from sklearn.feature_selection import VarianceThreshold
```

Загружаем датасет. Это вымышленный набор данных, созданный специалистами по данным IBM. https://www.kaggle.com/pavansubhasht/ibm-hr-analytics-attrition-dataset

```
ibm_hr_df = pd.read_csv("/content/sample_data/IBM-HR-Employee-Attrition.csv")
ibm_hr_df.head()
```

	Age	Attrition	BusinessTravel	DailyRate	Department	DistanceFromHome	Education	EducationField	EmployeeCount	EmployeeNumber	...	RelationshipSatisfaction	St
0	41	Yes	Travel_Rarely	1102	Sales	1	2	Life Sciences	1	1	...	1	
1	49	No	Travel_Frequently	279	Research & Development	8	1	Life Sciences	1	2	...	4	
2	37	Yes	Travel_Rarely	1373	Research & Development	2	2	Other	1	4	...	2	
3	33	No	Travel_Frequently	1392	Research & Development	3	4	Life Sciences	1	5	...	3	
4	27	No	Travel_Rarely	591	Research & Development	2	1	Medical	1	7	...	4	

5 rows × 35 columns

Рис.1 – Просмотр заголовка

Просмотр типов данных. Это данные типа object, int.

```
ibm_hr_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1470 entries, 0 to 1469
Data columns (total 35 columns):
Age                         1470 non-null int64
Attrition                   1470 non-null object
BusinessTravel              1470 non-null object
DailyRate                   1470 non-null int64
Department                  1470 non-null object
DistanceFromHome            1470 non-null int64
Education                   1470 non-null int64
EducationField              1470 non-null object
EmployeeCount               1470 non-null int64
EmployeeNumber              1470 non-null int64
EnvironmentSatisfaction     1470 non-null int64
Gender                      1470 non-null object
HourlyRate                  1470 non-null int64
JobInvolvement              1470 non-null int64
JobLevel                    1470 non-null int64
JobRole                     1470 non-null object
JobSatisfaction             1470 non-null int64
MaritalStatus               1470 non-null object
MonthlyIncome               1470 non-null int64
MonthlyRate                 1470 non-null int64
NumCompaniesWorked          1470 non-null int64
Over18                      1470 non-null object
OverTime                    1470 non-null object
PercentSalaryHike           1470 non-null int64
PerformanceRating           1470 non-null int64
RelationshipSatisfaction    1470 non-null int64
StandardHours               1470 non-null int64
StockOptionLevel            1470 non-null int64
TotalWorkingYears           1470 non-null int64
TrainingTimesLastYear       1470 non-null int64
WorkLifeBalance             1470 non-null int64
YearsAtCompany              1470 non-null int64
YearsInCurrentRole          1470 non-null int64
YearsSinceLastPromotion     1470 non-null int64
YearsWithCurrManager        1470 non-null int64
dtypes: int64(26), object(9)
memory usage: 402.0+ KB
```

Рис.2 – Типы данных

Получение сводной статистики набора данных IBM HR

```
ibm_hr_df.describe()
```

	Age	DailyRate	DistanceFromHome	Education	EmployeeCount	EmployeeNumber	EnvironmentSatisfaction	HourlyRate	JobInvolvement	JobLevel	...	Rela
count	1470.000000	1470.000000	1470.000000	1470.000000	1470.0	1470.000000	1470.000000	1470.000000	1470.000000	1470.000000	...	
mean	36.923810	802.485714	9.192517	2.912925	1.0	1024.865306	2.721769	65.891156	2.729932	2.063946	...	
std	9.135373	403.509100	8.106864	1.024165	0.0	602.024335	1.093082	20.329428	0.711561	1.106940	...	
min	18.000000	102.000000	1.000000	1.000000	1.0	1.000000	1.000000	30.000000	1.000000	1.000000	...	
25%	30.000000	465.000000	2.000000	2.000000	1.0	491.250000	2.000000	48.000000	2.000000	1.000000	...	
50%	36.000000	802.000000	7.000000	3.000000	1.0	1020.500000	3.000000	66.000000	3.000000	2.000000	...	
75%	43.000000	1157.000000	14.000000	4.000000	1.0	1555.750000	4.000000	83.750000	3.000000	3.000000	...	
max	60.000000	1499.000000	29.000000	5.000000	1.0	2068.000000	4.000000	100.000000	4.000000	5.000000	...	

8 rows × 26 columns

Рис.3 – Сводная статистика

Выявление нерелевантных атрибутов EmployeeCount и StandardHours

```
irrList = ['EmployeeCount', 'StandardHours']
ibm_hr_df[irrList].describe()
```

	EmployeeCount	StandardHours
count	1470.0	1470.0
mean	1.0	80.0
std	0.0	0.0
min	1.0	80.0
25%	1.0	80.0
50%	1.0	80.0
75%	1.0	80.0
max	1.0	80.0

Рис.4 - Атрибуты EmployeeCount и StandardHours

Выявление нерелевантного атрибута Over18

```
ibm_hr_df["Over18"].value_counts()
```

```
Y    1470
Name: Over18, dtype: int64
```

Рис.5 – Атрибут Over18

Из сводной статистики видно, что атрибуты EmployeeCount, StandardHours и Over18 содержат только одно значение для всех 1470 записей

- EmployeeCount содержит только одно значение - 1.0
- StandardHours содержит только одно значение - 80.0
- Over18 содержит только одно значение - 'Y'

Эти нерелевантные атрибуты удалим из набора данных

Проверка на неопределённые и отсутствующие значения

```
ibm_hr_df.isnull().sum(axis=0)
```

```
Age                         0
Attrition                   0
BusinessTravel              0
DailyRate                   0
Department                  0
DistanceFromHome            0
Education                   0
EducationField              0
EmployeeCount               0
EmployeeNumber              0
EnvironmentSatisfaction     0
Gender                      0
HourlyRate                  0
JobInvolvement              0
JobLevel                    0
JobRole                     0
JobSatisfaction             0
MaritalStatus               0
MonthlyIncome               0
MonthlyRate                 0
NumCompaniesWorked          0
Over18                      0
OverTime                    0
PercentSalaryHike           0
PerformanceRating           0
RelationshipSatisfaction    0
StandardHours               0
StockOptionLevel            0
TotalWorkingYears           0
TrainingTimesLastYear       0
WorkLifeBalance             0
YearsAtCompany              0
YearsInCurrentRole          0
YearsSinceLastPromotion     0
YearsWithCurrManager        0
dtype: int64
```

Рис.6 - Проверка на неопределённые и отсутствующие значения

Что ж, нам здесь повезло, в этом наборе данных нет пропущенных значений.

Далее проверим наличие повторяющихся записей в наборе данных.

```
ibm_hr_df.duplicated().sum()
```

В наборе данных также нет повторяющихся записей.

Преобразование двоичного категориального атрибута OverTime в {1, 0}

```
ibm_hr_df['OverTime'].replace(to_replace=dict(Yes=1, No=0), inplace=True)
```

Предварительная обработка данных

Удаление нерелевантных атрибутов

```
ibm_hr_df = ibm_hr_df.drop(['EmployeeCount', 'StandardHours', 'Over18'], axis=1
)
```

Выполнение корреляционного анализа Пирсона между атрибутами для облегчения уменьшения размерности

```
plt.figure(figsize=(16,16))
sns.heatmap(ibm_hr_df.corr(), annot=True, fmt=".2f")

plt.show()
```

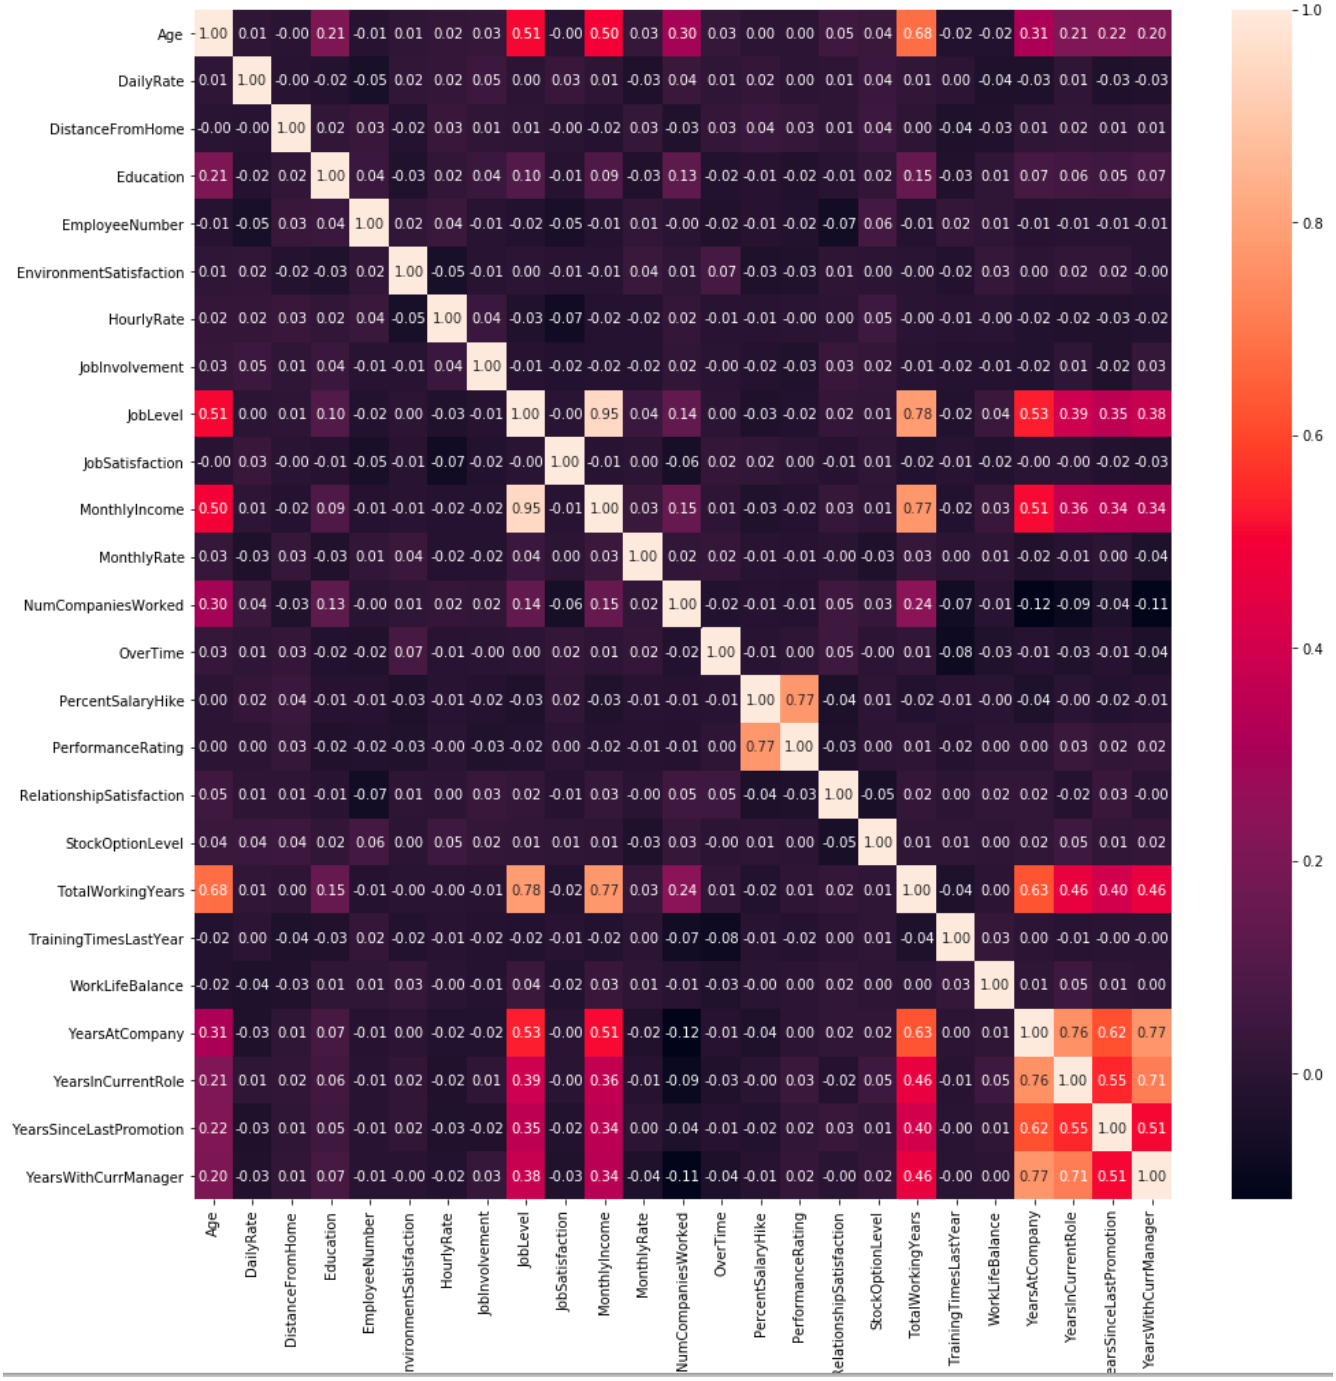

Рис.7 – Корреляционный анализ

Выполнение дисперсионного анализа

```
variance_x = ibm_hr_df.drop('Attrition', axis=1)
variance_one_hot = pd.get_dummies(variance_x)


#Нормализовать набор данных. Это необходимо для получения порога дисперсии.
```

```
scaler = MinMaxScaler()
scaler.fit(variance_one_hot)
MinMaxScaler(copy=True, feature_range=(0, 1))
scaled_variance_one_hot = scaler.transform(variance_one_hot)


#Установить пороговые значения и запустить VarianceThreshold
thres = .85* (1 - .85)
sel = VarianceThreshold(threshold=thres)
sel.fit(scaled_variance_one_hot)
variance = sel.variances_


#Сортировка в порядке возрастания для построения графика
indices = np.argsort(variance)[::-1]
feature_list = list(variance_one_hot)
sorted_feature_list = []
thres_list = []
for f in range(len(variance_one_hot.columns)):
    sorted_feature_list.append(feature_list[indices[f]])
    thres_list.append(thres)


plt.figure(figsize=(14,6))
plt.title("Feature Variance: %f" %(thres), fontsize = 14)
plt.bar(range(len(variance_one_hot.columns)), variance[indices], color="c")
plt.xticks(range(len(variance_one_hot.columns)), sorted_feature_list, rotation
= 90)
plt.xlim([-0.5, len(variance_one_hot.columns)])
plt.plot(range(len(variance_one_hot.columns)), thres_list, "k-", color="r")
plt.tight_layout()
plt.show()
```

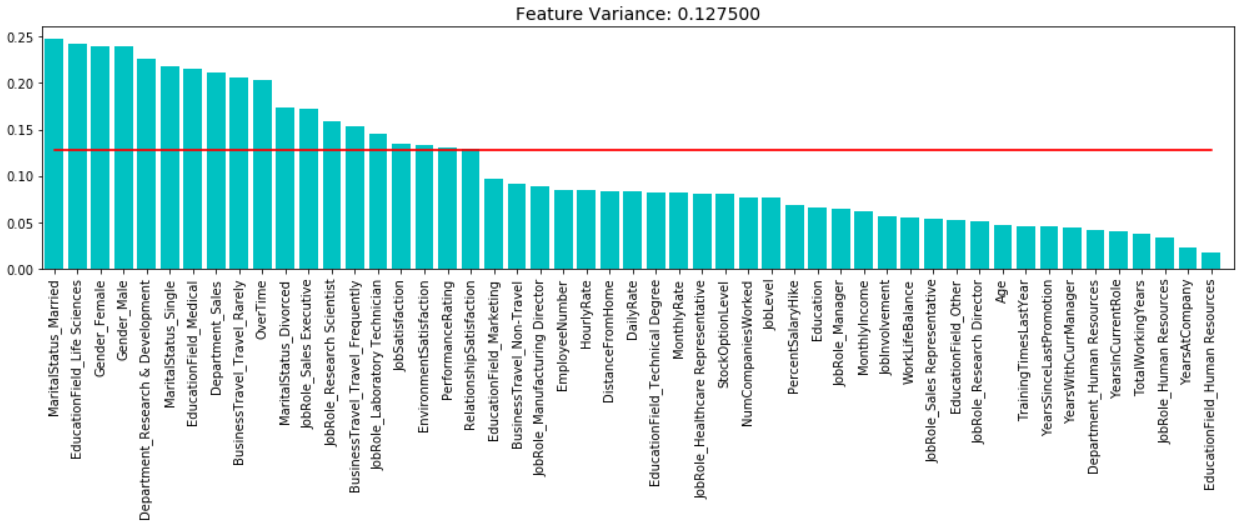


```
rAttrList = ['Department', 'OverTime', 'HourlyRate',
             'StockOptionLevel', 'DistanceFromHome',
             'YearsInCurrentRole', 'Age']


#храните только список атрибутов в rAttrList
label_hr_df = ibm_hr_df[rAttrList]


#преобразование непрерывного атрибута DistanceFromHome в категориальный
#: 1: близко, 2: среднее растояние, 3: далеко
maxValues = label_hr_df['DistanceFromHome'].max()
minValues = label_hr_df['DistanceFromHome'].min()
intervals = (maxValues - minValues)/3
bins = [0, (minValues + intervals), (maxValues - intervals), maxValues]
groupName = [1, 2, 3]
label_hr_df['CatDistanceFromHome'] = pd.cut(label_hr_df['DistanceFromHome'], bi
ns, labels = groupName)


# приведение типа к int64
label_hr_df['CatDistanceFromHome'] = pd.to_numeric(label_hr_df['CatDistanceFrom
Home'])
label_hr_df.drop(['DistanceFromHome'], axis = 1, inplace = True)


#переместить названия подразделений в 0 & 1, 0: R&D, and 1: Non-R&D
label_hr_df['Department'].replace(['Research & Development', 'Human Resources',
 'Sales'],
                                  [0, 1, 1], inplace = True)


#нормализация данных
```

```
label_hr_df_norm = (label_hr_df - label_hr_df.min()) / (label_hr_df.max() - lab
el_hr_df.min())


#создать data frame для значения функций и меток классов
value_df = pd.DataFrame(columns = ['ClassValue'])


#вычислить значение класса
for row in range (0, ibm_hr_df.shape[0]):
    if label_hr_df_norm['Department'][row] == 0:
        value = 0.3 * label_hr_df_norm['HourlyRate'][row] - 0.2 * label_hr_df_n
orm['OverTime'][row] + \
            - 0.2 * label_hr_df_norm['CatDistanceFromHome'][row] + 0.15 * label
_hr_df_norm['StockOptionLevel'][row] + \
            0.1 * label_hr_df_norm['Age'][row] - 0.05 * label_hr_df_norm['Years
InCurrentRole'][row]

    else:
        value = 0.2 * label_hr_df_norm['HourlyRate'][row] - 0.3 * label_hr_df_n
orm['OverTime'][row] + \
            - 0.15 * label_hr_df_norm['CatDistanceFromHome'][row] + 0.2 * label
_hr_df_norm['StockOptionLevel'][row] + \
            0.05 * label_hr_df_norm['Age'][row] - 0.1 * label_hr_df_norm['Years
InCurrentRole'][row]
    value_df.loc[row] = value


# top 500 высшего класса довольны своей работой
v1 = value_df.sort_values('ClassValue', ascending = False).reset_index(drop = T
rue)\
        ['ClassValue'][499]
# следующие top 500 нейтральны
v2 = value_df.sort_values('ClassValue', ascending = False).reset_index(drop = T
rue)\
        ['ClassValue'][999]
# остальные неудовлетворены своей работой


label_df = pd.DataFrame(columns = ['ClassLabel'])


#вычислить classlabel
for row in range (0, value_df.shape[0]):
    if value_df['ClassValue'][row] >= v1:
        cat = "Satisfied"
    elif value_df['ClassValue'][row] >= v2:
        cat = "Neutral"
```

```
    else:
        cat = "Unsatisfied"
    label_df.loc[row] = cat


df = pd.concat([ibm_hr_df, label_df], axis = 1)
```

Классификация

```
df = df[['Age', 'Department', 'DistanceFromHome', 'HourlyRate', 'OverTime', 'StockOptionLevel',
         'MaritalStatus', 'YearsInCurrentRole', 'EmployeeNumber', 'ClassLabel']
]
```

Разбиение данных на attributes/features X и label/class y

```
X = df.drop('ClassLabel', axis=1)
y = df.ClassLabel
```

Замена label/class значений из 'Satisfied', 'Neutral' и 'Unsatisfied' в 2, 1 and 0

```
y.replace(to_replace=dict(Satisfied=2, Neutral=1, Unsatisfied=0), inplace=True)
```

Выполнение 'one hot encoding' метода

```
one_hot = pd.get_dummies(X)
```

Нормализация функции

```
one_hot = (one_hot - one_hot.mean()) / (one_hot.max() - one_hot.min())
categorical_features_indices = np.where(one_hot.dtypes != np.float)[0]
```

Обучение

Теперь давайте разделим наши данные на обучающий (70%) и тестовый (30%) набор:

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(one_hot, y, train_size=0.7,
 random_state=1234)
```

```
model = CatBoostClassifier(
    custom_loss = ['Accuracy'],
    random_seed = 100,
    loss_function = 'MultiClass'
)


model.fit(
    X_train, y_train,
    cat_features = categorical_features_indices,
    verbose = True,
    #plot = True
)
```

```
Learning rate set to 0.079242
0:      learn: 1.0312448        total: 3.53ms   remaining: 3.52s
1:      learn: 0.9667097        total: 6.14ms   remaining: 3.06s
2:      learn: 0.9189766        total: 8.72ms   remaining: 2.9s
3:      learn: 0.8786445        total: 11.2ms   remaining: 2.79s
4:      learn: 0.8369363        total: 13.8ms   remaining: 2.75s
5:      learn: 0.7954649        total: 16.3ms   remaining: 2.7s
6:      learn: 0.7634820        total: 18.8ms   remaining: 2.67s
7:      learn: 0.7342294        total: 21.8ms   remaining: 2.7s
8:      learn: 0.7094003        total: 24.4ms   remaining: 2.68s
9:      learn: 0.6845187        total: 27.3ms   remaining: 2.7s
10:     learn: 0.6590169        total: 30.4ms   remaining: 2.74s
11:     learn: 0.6395683        total: 33.2ms   remaining: 2.73s

994:    learn: 0.0227453        total: 2.68s    remaining: 13.5ms
995:    learn: 0.0227280        total: 2.68s    remaining: 10.8ms
996:    learn: 0.0227062        total: 2.69s    remaining: 8.08ms
997:    learn: 0.0226718        total: 2.69s    remaining: 5.39ms
998:    learn: 0.0226477        total: 2.69s    remaining: 2.69ms
999:    learn: 0.0226263        total: 2.69s    remaining: 0us
<catboost.core.CatBoostClassifier at 0x7fbcdc7de450>
```

Рис.8 – Обучение

```
feature_score = pd.DataFrame(list(zip(one_hot.dtypes.index, model.get_feature_i
mportance(Pool(one_hot, label=y, cat_features=categorical_features_indices)))),
                columns=['Feature','Score'])
feature_score = feature_score.sort_values(by='Score', ascending=False, inplace=
False, kind='quicksort', na_position='last')


plt.rcParams["figure.figsize"] = (12,7)
ax = feature_score.plot('Feature', 'Score', kind='bar', color='c')
ax.set_title("Catboost Feature Importance Ranking", fontsize = 14)
ax.set_xlabel('')
```

```
rects = ax.patches

# get feature score as labels round to 2 decimal
labels = feature_score['Score'].round(2)

for rect, label in zip(rects, labels):
    height = rect.get_height()
    ax.text(rect.get_x() + rect.get_width()/2, height + 0.35, label, ha='center
', va='bottom')

plt.show()
```

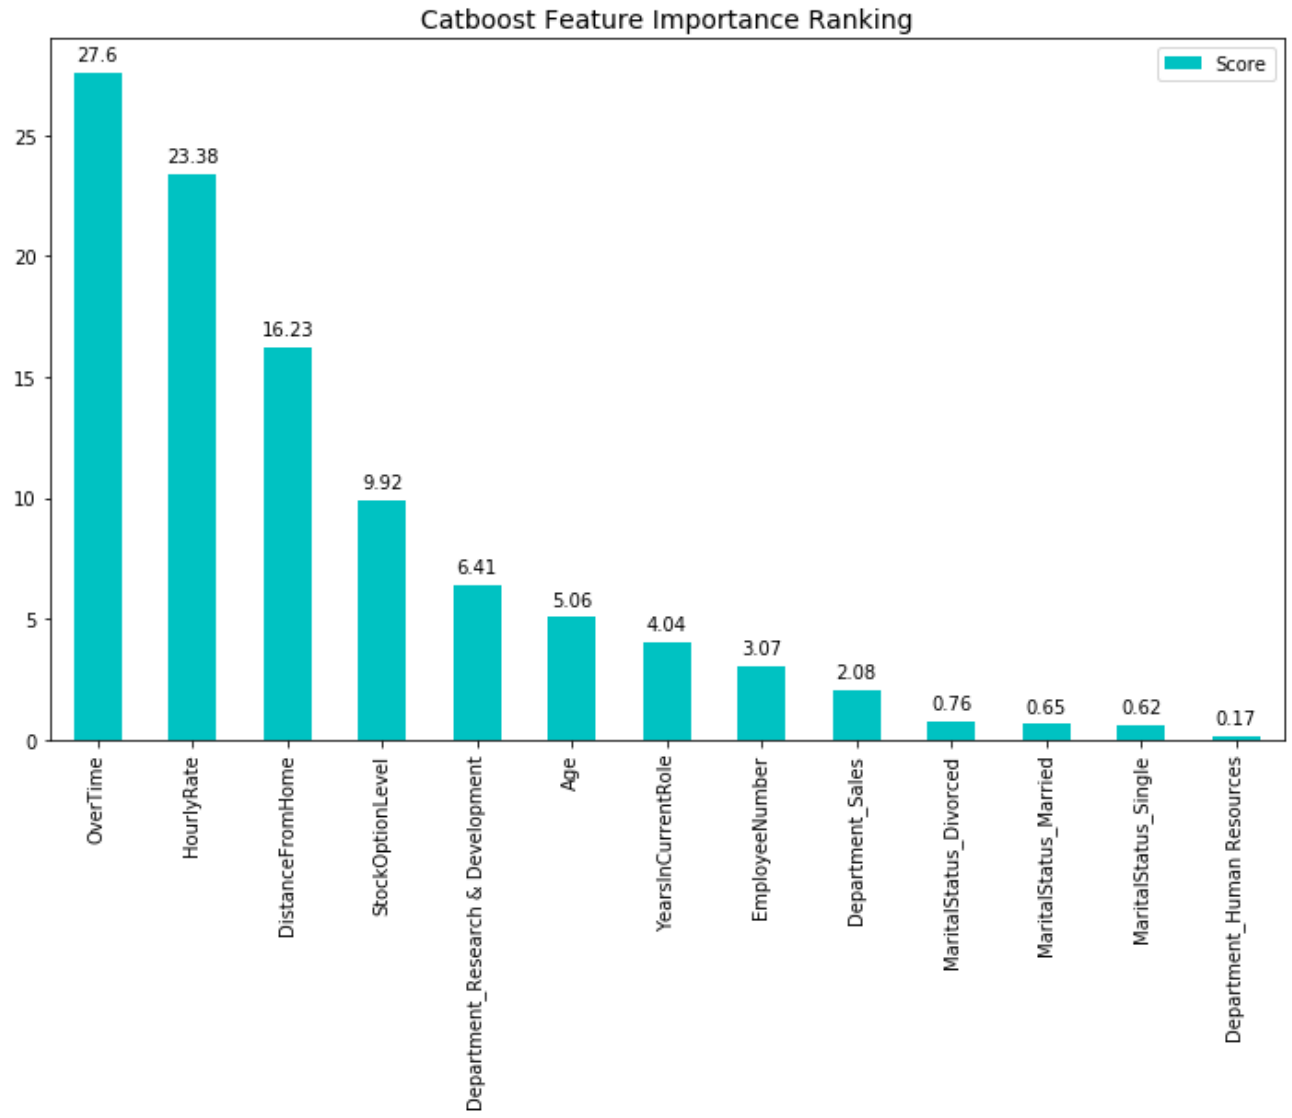

Рис.9 – Важность признаков

Как видно по графику, что наибольшей важностью обладает признак OverTime.

```
model.score(X_test, y_test)
0.9251700680272109
```

CatBoost настройка классификатора

```
model = CatBoostClassifier(
    l2_leaf_reg = 3,
    iterations = 1000,
    fold_len_multiplier = 1.05,
    learning_rate = 0.05,
    custom_loss = ['Accuracy'],
    random_seed = 100,
    loss_function = 'MultiClass'
)
```

```
model.fit(
    X_train, y_train,
    cat_features = categorical_features_indices,
    verbose = True,
    #plot = True
)
```

```
          0:      learn: 1.0555929        total: 2.82ms   remaining: 2.81s
          1:      learn: 1.0125553        total: 5.68ms   remaining: 2.83s
          2:      learn: 0.9792847        total: 8.16ms   remaining: 2.71s
          3:      learn: 0.9478631        total: 10.6ms   remaining: 2.64s
          4:      learn: 0.9167174        total: 13.4ms   remaining: 2.66s
          5:      learn: 0.8869031        total: 15.8ms   remaining: 2.62s
        994:    learn: 0.0397018        total: 2.74s    remaining: 13.8ms
        995:    learn: 0.0396683        total: 2.74s    remaining: 11ms
        996:    learn: 0.0396387        total: 2.74s    remaining: 8.25ms
        997:    learn: 0.0395917        total: 2.74s    remaining: 5.5ms
        998:    learn: 0.0395204        total: 2.75s    remaining: 2.75ms
        999:    learn: 0.0394835        total: 2.75s    remaining: 0us
        <catboost.core.CatBoostClassifier at 0x7fbcdc8c4d90>
```

Рис.10 – Обучение

```
feature_score = pd.DataFrame(list(zip(one_hot.dtypes.index, model.get_feature_i
mportance(Pool(one_hot, label=y, cat_features=categorical_features_indices)))),
               columns=['Feature','Score'])
```

```
feature_score = feature_score.sort_values(by='Score', ascending=False, inplace=
False, kind='quicksort', na_position='last')


plt.rcParams["figure.figsize"] = (12,7)
ax = feature_score.plot('Feature', 'Score', kind='bar', color='c')
ax.set_title("Catboost Feature Importance Ranking", fontsize = 14)
ax.set_xlabel('')

rects = ax.patches

# get feature score as labels round to 2 decimal
labels = feature_score['Score'].round(2)

for rect, label in zip(rects, labels):
    height = rect.get_height()
    ax.text(rect.get_x() + rect.get_width()/2, height + 0.35, label, ha='center
', va='bottom')

plt.show()
#plt.savefig("image.png")
```

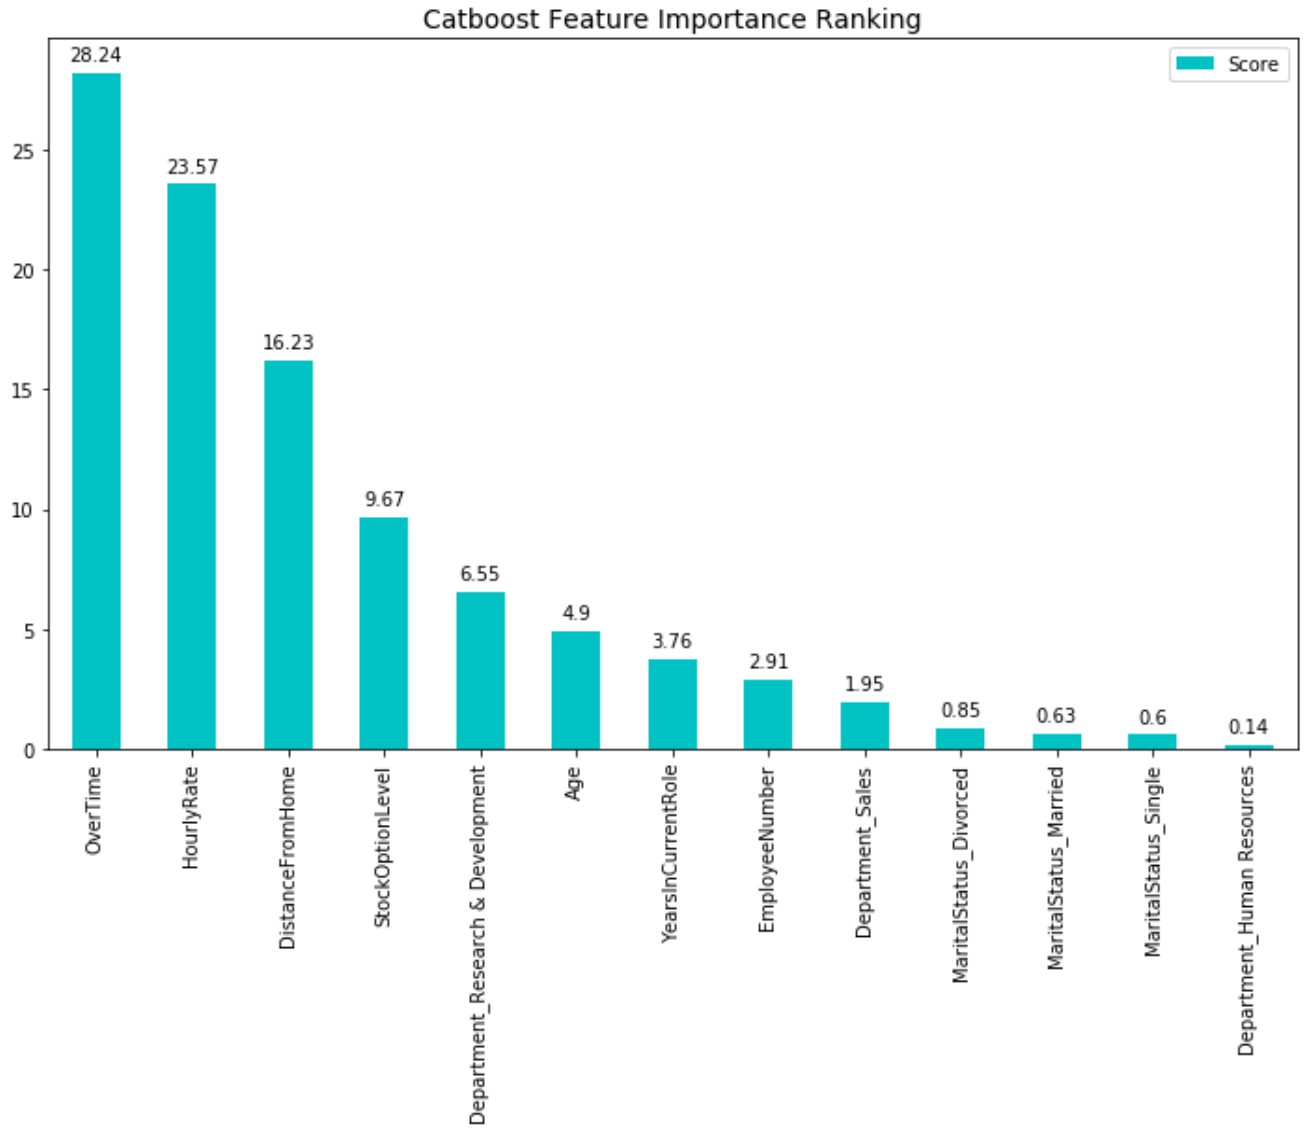

Рис.11 – Важность признаков

Как видно по графику, что наибольшей важностью обладает признак OverTime.

```
cm = pd.DataFrame()
cm['Satisfaction'] = y_test
cm['Predict'] = model.predict(X_test)
```

```
mappingSatisfaction = {0:'Unsatisfied', 1: 'Neutral', 2: 'Satisfied'}
mappingPredict = {0.0:'Unsatisfied', 1.0: 'Neutral', 2.0: 'Satisfied'}
cm = cm.replace({'Satisfaction': mappingSatisfaction, 'Predict': mappingPredict
})
```

```
pd.crosstab(cm['Satisfaction'], cm['Predict'], margins=True)
```

Predict	Neutral	Satisfied	Unsatisfied	All
Satisfaction				
Neutral	144	11	5	160
Satisfied	9	136	0	145
Unsatisfied	8	0	128	136
All	161	147	133	441

Рис.12 – Таблица удовлетворённости сотрудников

```
model.score(X_test, y_test)
0.9251700680272109
```

Вывод

В данной курсовой работе была произведена подготовка и анализ данных факторов, влияющих на увольнение сотрудников. С использование библиотеки CatBoost были выявлены наиболее значимые факторы.

Список использованной литературы

1. https://catboost.ai/docs - CatBoost documentation
2. https://www.kaggle.com/pavansubhasht/ibm-hr-analytics-attrition-dataset - kaggle
3. https://gist.github.com/talperetz/6030f4e9997c249b09409dcf00e78f91 - Catboost Playground
4. https://towardsdatascience.com/https-medium-com-talperetz24-mastering-the-new-generation-of-gradient-boosting-db04062a7ea2 - Mastering The New Generation of Gradient Boosting - Tal Peretz